



evaluación comparativa de modelos de machine learning para la predicción de insolvencia empresarial en Colombia

Andrés Hernando Cerquera Mejía

Asesor
Mauricio Lopera Castaño

Universidad de Antioquia
Facultad de Ciencias Económicas
Medellín
2026

Índice

Índice	2
Lista de tablas	4
1. Introducción	6
2. Marco teórico	7
2.1. Fundamento jurídico	7
2.2. Antecedentes y literatura previa	7
2.3. Evolución de los modelos de predicción	9
2.4. Fundamentos de los modelos predictivos empleados	10
2.4.1. Regresión logística (Logit)	10
2.4.2. Modelos aditivos generalizados (GAM)	11
2.4.3. Boosting y XGBoost	11
3. Planteamiento del problema	13
3.0.1. Objetivo General	15
3.0.2. Objetivos Específicos	15
4. Metodología	15
4.1. Fuentes de información y construcción de la base de datos	15
4.2. Definición de la variable dependiente y estructura de la muestra	16
4.3. Variables explicativas	17
4.4. Preprocesamiento de los datos	18
4.5. Estrategia de partición, validación y entrenamiento	19
4.6. Especificación de los modelos	20
4.7. Criterios de evaluación y selección del modelo	21

5.	Resultados	22
5.1.	Comparación financiera entre grupos	22
5.2.	Resultados de los modelos predictivos	23
5.2.1.	Horizonte 2024	23
5.2.2.	Horizonte 2024–2025	25
5.2.3.	Síntesis comparativa	27
6.	Discusión y conclusiones	27
7.	Referencias	29
8.	Anexos	31

Lista de tablas

1.	Distribución de empresas – Horizonte 1 año	17
2.	Distribución de empresas – Horizonte 2 años	17
3.	Indicadores financieros utilizados en los modelos	18
4.	Dimensiones financieras e indicadores utilizados en los modelos	19
5.	Diferencias entre grupos a un año (2024)	23
6.	Diferencias entre grupos a dos años (2024–2025)	24
7.	Matriz de confusión – Horizonte 2024	25
8.	Métricas de desempeño de los modelos en 2024	25
9.	Matriz de confusión – Horizonte 2024–2025	26
10.	Métricas de desempeño de los modelos en 2024–2025	27

Lista de anexos

Anexo 1. Agrupación de variables y criterios de winsorización	32
Anexo 2. Matriz de correlación entre variables explicativas	32
Anexo 3. Resultados del factor de inflación de la varianza (VIF)	33

1. Introducción

El riesgo de quiebra e insolvencia empresarial en Colombia ha adquirido una relevancia creciente en un entorno caracterizado por volatilidad económica, altos costos financieros, competencia intensa y cambios regulatorios. A ello se suman problemas asociados con el endeudamiento, la gestión de la liquidez y las fluctuaciones en la demanda, factores que incrementan la vulnerabilidad de las empresas y refuerzan la necesidad de contar con herramientas que permitan identificar de manera temprana señales de deterioro financiero (Confecamaras, 2018; Cruz, 2022).

La dinámica empresarial reciente confirma esta vulnerabilidad. Entre 2013 y 2017, la economía colombiana registró altas tasas de entrada y salida de empresas, cercanas al 19% anual, y de cada 100 firmas creadas formalmente en 2012 solo 34 sobrevivieron después de cinco años. Aunque la permanencia fue relativamente mayor en sectores como construcción e industria, estos resultados evidencian la importancia de fortalecer mecanismos de monitoreo y acompañamiento desde etapas tempranas, con el fin de reducir la probabilidad de insolvencia y mejorar la sostenibilidad empresarial (Confecamaras, 2018).

En este contexto, la predicción temprana de la insolvencia constituye una herramienta útil para empresas, auditores, acreedores e instituciones financieras, en la medida en que permite apoyar decisiones crediticias, monitorear el desempeño empresarial y adoptar medidas correctivas antes de la materialización del evento de insolvencia (Valencia et al., 2019). En Colombia, esta problemática se encuentra enmarcada por la Ley 1116 de 2006, que establece el régimen de reorganización empresarial e insolvencia y proporciona mecanismos para la reestructuración de empresas en dificultades financieras (Molina y Gonzales, 2024). Por esta razón, resulta especialmente relevante que las entidades de supervisión y los diseñadores de política pública cuenten con instrumentos que permitan identificar empresas con mayor probabilidad de entrar en insolvencia y, con ello, anticipar medidas preventivas que mitiguen sus efectos económicos y sociales (Cruz, 2022).

A partir de lo anterior, el objetivo de este estudio es construir y comparar modelos predictivos que permitan estimar de forma anticipada la probabilidad de insolvencia empresarial a partir de variables financieras relevantes. A diferencia de trabajos previos que se concentran principalmente en un único horizonte predictivo, esta investigación evalúa dos horizontes de análisis: un horizonte de un año, asociado con empresas que ingresan en procesos de insolvencia durante 2024, y un horizonte de dos

años, asociado con empresas que ingresan en procesos de insolvencia durante 2024 o 2025. Para ello, se contrastan metodologías tradicionales, como la regresión logística, con enfoques más flexibles, como los modelos aditivos generalizados y técnicas de *boosting*, con el fin de evaluar su capacidad para clasificar empresas en riesgo y no riesgo de insolvencia. La selección de variables y la estrategia de validación se fundamentan en la literatura previa y en criterios apropiados para problemas de clasificación con clases desbalanceadas, con énfasis en la detección temprana y en el análisis de los errores tipo I y tipo II (D. Correa y Lopera, 2020).

En consecuencia, esta investigación busca aportar evidencia empírica sobre la utilidad de los modelos predictivos en la gestión del riesgo de insolvencia empresarial en Colombia, así como contribuir al diseño de herramientas de alerta temprana para empresas, acreedores, instituciones financieras y organismos de supervisión.

2. Marco teórico

2.1. Fundamento jurídico

En Colombia, la insolvencia empresarial está regulada por la Ley 1116 de 2006, la cual establece mecanismos para atender la cesación de pagos y la incapacidad de pago inminente de personas naturales y jurídicas. En este marco, la detección temprana del riesgo de insolvencia es fundamental, ya que permite anticipar decisiones orientadas a mitigar impactos económicos y sociales, proteger el empleo y fortalecer la política pública (Martínez, 2003).

2.2. Antecedentes y literatura previa

Los enfoques tradicionales de predicción de insolvencia se originan en el Z-score de Altman (1968) y en la regresión logística propuesta por Ohlson (1980), los cuales establecieron el uso de razones financieras como base para anticipar el riesgo empresarial. En décadas recientes, la literatura ha ampliado este enfoque mediante la incorporación de variables macroeconómicas, indicadores de gestión y técnicas de *machine learning*, con el propósito de mejorar la capacidad predictiva frente a los modelos estadísticos tradicionales (Franco, 2023; Ramírez y Roa, 2015).

En Colombia, Salgado (2018) estudian una muestra de 796 empresas del sector

industrial en Bogotá durante el periodo 2010–2016 y aplican modelos de análisis discriminante múltiple, logit y probit, destacando la capacidad predictiva del análisis discriminante dentro de su muestra. De manera complementaria, D. Correa y Lopera (2019) utilizan indicadores financieros de rentabilidad, como el ROA, el ROE y los márgenes de utilidad, así como variables de endeudamiento y apalancamiento, para pronosticar la insolvencia empresarial con un año de anticipación en una muestra de 2.988 empresas colombianas. El estudio compara el desempeño de la regresión logística con un algoritmo boosting, encontrando que este último presenta una mejor capacidad predictiva (D. Correa y Lopera, 2019).

Dado que la insolvencia empresarial constituye un evento de baja frecuencia y de alto costo cuando no se detecta oportunamente, la evaluación de los modelos debe privilegiar criterios consistentes con un enfoque de alerta temprana, particularmente la sensibilidad y la reducción del Error Tipo II (D. Correa y Lopera, 2019; Perez et al., 2017). En respuesta a ello, se han desarrollado enfoques más adecuados para eventos raros, como el modelo binario aditivo de valor extremo generalizado (BGEVA), que combina una función de enlace de valor extremo con estructuras semiparamétricas. En este sentido, Perez et al. (2017) analizan la discriminación entre empresas en quiebra y no quiebra para el periodo 2011–2015, comparando un modelo logístico, un modelo aditivo generalizado (GAM), un modelo de valor extremo generalizado y un modelo BGEVA, encontrando que este último ofrece el mejor desempeño predictivo.

Más recientemente, la literatura ha mostrado una transición hacia metodologías de aprendizaje automático, motivada por la necesidad de capturar relaciones no lineales, interacciones complejas y estructuras de datos altamente heterogéneas (Cruz, 2022; Franco, 2023; Zhang et al., 2024). Cruz (2022) destacan que, en el problema de insolvencia empresarial en Colombia, los predictores se relacionan de formas que no siempre pueden ser detectadas por técnicas tradicionales, por lo que modelos como árboles de decisión y boosting presentan un mejor desempeño de pronóstico que los enfoques lineales. En la misma línea, Brédart y Correa-Mejía (2022) muestran que, mediante boosting, es posible alcanzar una precisión global del 94,4 % y una tasa de error tipo I inferior al 5 % en un estudio aplicado a empresas en Bélgica, evidenciando la capacidad de estos algoritmos para reducir errores críticos de clasificación.

La superioridad predictiva de los modelos de *machine learning* también ha sido documentada en estudios recientes. Franco (2023) encuentran que algoritmos como XGBoost, SVM, Random Forest y Decision Trees presentan mejores resultados pre-

dictivos que las metodologías tradicionales, especialmente cuando la predicción se realiza un año antes del evento y se combinan variables financieras y no financieras. Asimismo, Molina y Gonzales (2024) desarrollan un modelo predictivo basado en aprendizaje automático para anticipar la insolvencia económica de PYMES colombianas a partir de información financiera y sociodemográfica. Por su parte, Aristizabal (2025) comparan modelos de regresión logística, Random Forest y redes neuronales para predecir el *default* de PYMES en Medellín con datos de 2023, evaluando su desempeño mediante métricas como precisión, sensibilidad, especificidad y exactitud. Mas recientemente Iparraguirre-Villanueva y Cabanillas-Carbonell (2024) reportan que algoritmos como *Stacking Classifier*, *Randomized Search Classifier* y *Decision Tree* alcanzan métricas superiores al 97% en exactitud y *recall*, lo que refuerza la idea de que las técnicas avanzadas de clasificación pueden mejorar sustancialmente la gestión del riesgo.

En conjunto, la literatura muestra una transición desde modelos estadísticos tradicionales hacia enfoques de aprendizaje automático con mayor capacidad para capturar no linealidades, interacciones complejas y desbalance de clases (Cruz, 2022; Franco, 2023; Perez et al., 2017). Aunque los modelos clásicos siguen siendo útiles por su interpretabilidad y como línea base, la evidencia reciente sugiere que los algoritmos de *machine learning* pueden mejorar la predicción temprana del riesgo de insolvencia (D. Correa y Lopera, 2019; Iparraguirre-Villanueva y Cabanillas-Carbonell, 2024; Zhang et al., 2024). En este contexto, la presente investigación se orienta a comparar ambos enfoques con el fin de identificar cuáles ofrecen un mejor desempeño en la anticipación de la insolvencia empresarial en Colombia.

2.3. Evolución de los modelos de predicción

La evolución metodológica en la predicción de insolvencia empresarial puede agruparse en cuatro líneas principales. Primero, los modelos tradicionales, como el análisis discriminante, la regresión logística y el probit, han sido ampliamente utilizados con resultados satisfactorios en el contexto colombiano (D. Correa y Lopera, 2019; Ramirez y Roa, 2015; Salgado, 2018). Segundo, la literatura coincide en la relevancia de variables financieras como la rentabilidad del activo, la rentabilidad del patrimonio, el endeudamiento y la razón corriente como predictores del deterioro financiero (D. Correa y Lopera, 2019; Perez et al., 2017). Tercero, dado que la insolvencia es un evento de baja frecuencia, se han propuesto modelos más adecuados para eventos raros, como el BGEVA, que mejora el desempeño frente a especificaciones

logísticas tradicionales (Perez et al., 2017). Finalmente, los modelos de *machine learning*, entre ellos Random Forest, XGBoost, árboles de decisión y *Stacking Classifier*, han mostrado mejoras en exactitud y *recall* frente a varios enfoques convencionales dentro de eventos raros de insolvencia (Franco, 2023; Iparraguirre-Villanueva y Cabanillas-Carbonell, 2024).

2.4. Fundamentos de los modelos predictivos empleados

Con el fin de evaluar la capacidad de anticipación del riesgo de insolvencia empresarial, esta investigación compara tres enfoques con distinto nivel de complejidad: la regresión logística, los modelos aditivos generalizados (GAM) y XGBoost. La selección de estos modelos responde a una lógica metodológica escalonada: un modelo base interpretable, un modelo semiparamétrico capaz de capturar no linealidades y un algoritmo de aprendizaje automático orientado a maximizar la capacidad predictiva en problemas de clasificación desbalanceada (Cruz, 2022; Perez et al., 2017; Zhang et al., 2024).

2.4.1. Regresión logística (Logit)

La regresión logística es un modelo de clasificación binaria que estima la probabilidad de ocurrencia de un evento, como la insolvencia, en función de un conjunto de covariables. En el marco de los modelos lineales generalizados, su formulación se expresa a través de la función logit:

$$\text{logit}(P_i) = \ln \left(\frac{P_i}{1 - P_i} \right) = \beta_0 + \sum_{j=1}^k \beta_j x_{ij}, \quad (1)$$

donde $P_i = P(Y_i = 1 \mid X_i)$ representa la probabilidad de insolvencia de la empresa i (N. Correa, 2023). Su principal ventaja radica en la interpretabilidad de los coeficientes y en su uso como línea base en problemas de clasificación binaria. No obstante, su estructura lineal puede limitar su desempeño cuando las relaciones entre variables financieras y riesgo de insolvencia son no lineales o cuando el evento es de baja frecuencia (N. Correa, 2023; Perez et al., 2017).

2.4.2. Modelos aditivos generalizados (GAM)

Los modelos aditivos generalizados amplían la regresión logística al permitir que el efecto de cada covariable se modele mediante funciones suaves, en lugar de asumir una relación estrictamente lineal. Su forma general puede expresarse como:

$$g(\mathbb{E}[Y_i | X_i]) = \beta_0 + \sum_{j=1}^p f_j(x_{ij}), \quad (2)$$

y, para clasificación binaria, suele emplearse la función logit:

$$\text{logit}(P_i) = \beta_0 + \sum_{j=1}^p f_j(x_{ij}), \quad (3)$$

donde $f_j(\cdot)$ representa funciones suaves de las covariables (Mazo, 2022). Este enfoque resulta pertinente en insolvencia empresarial, ya que permite capturar umbrales, curvaturas y efectos no lineales frecuentes en indicadores financieros, manteniendo un nivel razonable de interpretabilidad (Mazo, 2022; Perez et al., 2017). En este sentido, constituye una alternativa intermedia entre los modelos lineales tradicionales y los algoritmos de mayor complejidad.

2.4.3. Boosting y XGBoost

El *boosting* es una familia de métodos de ensamble que construye un clasificador fuerte a partir de la combinación secuencial de clasificadores débiles. Dentro de esta familia, XGBoost se ha consolidado como una de las herramientas más utilizadas por su eficiencia computacional, su capacidad para capturar interacciones y no linealidades, y sus mecanismos de regularización para controlar el sobreajuste. Su estructura puede representarse como un ensamble aditivo de árboles:

$$F(x) = \sum_{t=1}^T f_t(x), \quad (4)$$

estimado mediante la minimización de una función objetivo que combina pérdida de ajuste y penalización por complejidad:

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t). \quad (5)$$

Esta formulación regularizada contribuye a controlar el sobreajuste y mejorar la capacidad de generalización del modelo en problemas de clasificación (Liu et al., 2022).

En problemas de insolvencia empresarial, XGBoost es especialmente útil cuando existen relaciones complejas entre predictores, heterogeneidad empresarial y desbalance de clases, condiciones frecuentes en la identificación temprana del riesgo. La literatura ha mostrado que los modelos basados en árboles y técnicas de *boosting* pueden mejorar el desempeño predictivo frente a modelos lineales tradicionales en contextos de insolvencia y clasificación desbalanceada (D. Correa y Lopera, 2019; Cruz, 2022; Zhang et al., 2024). Por ello, en esta tesis se incorpora como el enfoque de mayor flexibilidad predictiva frente a los modelos tradicionales.

3. Planteamiento del Problema

En Colombia, la insolvencia empresarial se encuentra regulada por la Ley 1116 de 2006, la cual establece mecanismos para atender situaciones de cesación de pagos e incapacidad de pago inminente de personas naturales y jurídicas. En este marco, la apertura de un proceso concursal responde a la necesidad de evaluar si el deudor puede cumplir oportunamente sus obligaciones y, en caso contrario, activar instrumentos orientados a la reorganización o liquidación patrimonial. Por ello, la detección temprana del riesgo de insolvencia constituye un asunto de especial relevancia económica y social, en la medida en que puede aportar insumos para la toma de decisiones empresariales, la supervisión institucional y el diseño de políticas públicas orientadas a mitigar efectos sobre el empleo y el bienestar social (Cruz, 2022).

La importancia del problema se acentúa en el caso de las micro, pequeñas y medianas empresas (MIPYMES), que representan una proporción predominante del tejido empresarial colombiano y contribuyen de manera significativa al empleo y a la actividad económica del país. En este sentido, la insolvencia económica de estas unidades productivas no solo compromete su continuidad operativa, sino que también genera efectos agregados sobre la estabilidad empresarial, la generación de ingresos y la dinámica productiva nacional. De acuerdo con ANIF (2021), las MIPYMES representan el 99 % del tejido empresarial, generan cerca del 80 % del empleo y aportan aproximadamente el 35 % del PIB nacional.

A lo anterior se suma la reducida tasa de supervivencia empresarial en el país. Según el estudio *La supervivencia empresarial en Colombia* de Confecamaras (2023), únicamente el 33,5 % de las empresas sobrevive al cabo de cinco años, proporción inferior a la observada en varios países de la OCDE, donde la supervivencia empresarial a ese horizonte supera el 40 %. Esta evidencia sugiere la existencia de fragilidades estructurales que hacen necesario fortalecer los mecanismos de identificación temprana del deterioro financiero y del riesgo de insolvencia.

Desde la perspectiva analítica, si bien los modelos tradicionales de predicción, como el Z-score de Altman y los enfoques basados en razones financieras, han sido ampliamente utilizados para anticipar escenarios de deterioro empresarial, estos presentan limitaciones cuando el fenómeno de interés depende de relaciones no lineales, interacciones complejas entre predictores y contextos de alta volatilidad económica. En economías como la colombiana, dichas limitaciones pueden ser especialmente

relevantes debido a la heterogeneidad empresarial, la sensibilidad a choques macroeconómicos, la exposición a cambios regulatorios y el carácter poco frecuente del evento de insolvencia. En este contexto, los modelos de aprendizaje automático ofrecen una alternativa metodológica capaz de incorporar estructuras más complejas de información y mejorar la capacidad predictiva frente a los enfoques lineales convencionales (Kumar y Ravi, 2007; Tinoco y Wilson, 2013).

En consecuencia, el problema de investigación se centra en determinar si, para el caso colombiano, los modelos de aprendizaje automático permiten anticipar con mayor precisión el riesgo de insolvencia empresarial que los modelos estadísticos tradicionales. Esta pregunta resulta particularmente relevante en un contexto en el que la insolvencia constituye un evento raro, pero con altos costos económicos y sociales. Bajo esta perspectiva, la presente investigación no busca únicamente comparar el desempeño global de distintos modelos predictivos, sino identificar cuál ofrece una mejor capacidad de detección temprana de empresas en riesgo de insolvencia en el contexto colombiano. A diferencia de trabajos previos que se concentran principalmente en un único horizonte predictivo, este estudio evalúa dos horizontes de análisis: un horizonte de un año, asociado con empresas que ingresan en procesos de insolvencia durante 2024, y un horizonte acumulado de dos años, asociado con empresas que ingresan en procesos de insolvencia durante 2024 o 2025. Con ello, se espera contribuir al fortalecimiento de herramientas de análisis para empresas, entidades supervisoras y formuladores de política pública.

3.0.1. Objetivo General

Comparar modelos de *machine learning* para clasificar empresas colombianas en riesgo de insolvencia, utilizando variables financieras relevantes y evaluando su desempeño en horizontes predictivos de uno y dos años.

3.0.2. Objetivos Específicos

- Analizar y seleccionar variables financieras y contables relevantes para la predicción de insolvencia en empresas colombianas.
- Estimar modelos de clasificación supervisada, incluyendo regresión logística, GAM y XGBoost, para predecir el riesgo de insolvencia empresarial en horizontes predictivos de uno y dos años.
- Comparar el desempeño de los modelos utilizando métricas adecuadas para datos desbalanceados.
- Identificar el modelo con mejor capacidad de alerta temprana para la detección de empresas colombianas en riesgo de insolvencia.

4. Metodología

4.1. Fuentes de información y construcción de la base de datos

Se emplearon los estados de situación financiera y los estados de resultados integrales de empresas colombianas reportados a la Superintendencia de Sociedades, con corte a diciembre de 2023 y disponibles en el Sistema Integrado de Información Societaria (SIIS). La base incluye reportes presentados bajo los cuatro puntos de entrada establecidos por la entidad supervisora y asociados a los marcos técnicos NIIF para los Grupos 1 y 2: NIIF Plenas-Individual, NIIF Plenas-Separado, NIIF Pymes-Individual y NIIF Pymes-Separado. Esta clasificación permite incorporar empresas con distintos niveles de complejidad contable, estructural y operativa, lo cual puede incidir en el comportamiento de los indicadores financieros y, por tanto, en el análisis del riesgo de insolvencia.

Adicionalmente, se utilizó la base oficial de empresas en proceso de insolvencia descargada en noviembre de 2025. Esta fuente agrupa dos tipos de procedimientos:

(i) reorganización, orientada a preservar empresas viables mediante acuerdos que permitan normalizar sus relaciones comerciales y crediticias, y (ii) liquidación judicial, cuyo objetivo es realizar una liquidación pronta y ordenada del patrimonio del deudor (Superintendencia de sociedades, 2025).

La construcción de la base analítica se realizó mediante la unificación de la información financiera de 2023 con la base de insolvencia correspondiente a los años 2024 y 2025. La unión entre ambas fuentes se llevó a cabo utilizando el NIT como llave principal, lo que permitió asociar a cada empresa sus indicadores financieros previos con su estado posterior de insolvencia o no insolvencia.

4.2. Definición de la variable dependiente y estructura de la muestra

A partir de la base consolidada, se construyeron dos variables dependientes binarias que permiten evaluar el desempeño predictivo de los modelos en distintos horizontes temporales. La primera corresponde al riesgo de insolvencia a un año y toma el valor de 1 si la empresa inició un proceso de reorganización o liquidación durante 2024, y 0 en caso contrario. La segunda corresponde al riesgo de insolvencia a dos años y toma el valor de 1 si la empresa ingresó en proceso de insolvencia durante 2024 o 2025, y 0 si no presentó dicho evento en ese período. Esta estrategia permite diferenciar la capacidad de alerta temprana de los modelos en el corto y mediano plazo.

La muestra inicial estuvo compuesta por 31.276 empresas colombianas con información financiera reportada para 2023. Tras el proceso de depuración y exclusión de observaciones con valores faltantes en variables clave, la muestra final quedó conformada por 27.926 empresas.

Para el horizonte de un año, la Tabla 1 muestra que 300 empresas fueron clasificadas como insolventes y 27.626 como no insolventes, lo que equivale a una incidencia de 1,07 % de la clase positiva. Para el horizonte de dos años, la Tabla 2 muestra que 564 empresas fueron clasificadas como insolventes y 27.362 como no insolventes, correspondiente a una incidencia de 2,02 %. En ambos casos, la distribución confirma que la insolvencia empresarial constituye un evento de baja frecuencia, por lo que el problema empírico se caracteriza por un marcado desbalance de clases.

Con el fin de evaluar la capacidad predictiva de los modelos en un horizonte temporal

Tab. 1: Distribución de empresas – Horizonte 1 año

Categoría	Empresas	Frecuencia
No insolventes	27.626	98,93 %
Insolventes	300	1,07 %
Total	27.926	100 %

Fuente: elaboración propia.

más amplio, se define un segundo horizonte de dos años. En este caso, una empresa es clasificada como insolvente si ingresa en un proceso de insolvencia durante los años 2024 o 2025. La Tabla 2 muestra que 564 empresas fueron clasificadas como insolventes y 27.362 como no insolventes, lo que corresponde a una incidencia de 2,02 %. En ambos casos, la distribución confirma que la insolvencia empresarial constituye un evento de baja frecuencia, por lo que el problema se caracteriza por un marcado desbalance de clases.

Tab. 2: Distribución de empresas – Horizonte 2 años

Categoría	Empresas	Frecuencia
No insolventes	27.362	97,98 %
Insolventes	564	2,02 %
Total	27.926	100 %

Fuente: elaboración propia.

4.3. Variables explicativas

Las variables explicativas utilizadas en los modelos corresponden a indicadores financieros contruidos a partir de los estados de situación financiera y de resultados integrales (véase Tabla 3). Estos indicadores fueron agrupados en tres dimensiones: liquidez, rentabilidad y endeudamiento/apalancamiento (véase Tabla 4). La selección se fundamenta en la literatura sobre predicción de insolvencia empresarial, que identifica estas dimensiones como determinantes del deterioro financiero y del riesgo de incumplimiento (D. Correa y Lopera, 2019; Perez et al., 2017; Ramirez y Roa, 2015). En particular, se incluyeron razones asociadas con la capacidad de pago de corto plazo, la generación de utilidades y la estructura de financiamiento, entre ellas

la razón corriente, la razón de tesorería, el margen neto, el ROA, el ROE, el nivel de endeudamiento y el apalancamiento total. Dado que el SIIS reporta las cifras contables en miles de pesos colombianos, todos los cálculos se interpretaron en esa misma escala; es decir, una unidad en la base equivale a COP 1.000. Esta consideración fue relevante para la construcción de razones financieras y para el tratamiento de denominadores cercanos a cero.

Tab. 3: Indicadores financieros utilizados en los modelos

Abreviación	Indicador	Fórmula
raz	Razón corriente	$\text{Activos corrientes} / \text{Pasivos corrientes}$
teso	Razón de tesorería	$\text{Efectivo y equivalentes} / \text{Pasivos corrientes}$
ctno_ventas_pre- ciso	CTNO / Ventas	$\text{Activos corrientes operac.} - \text{Pasivos Corrientes Operac.} / \text{Ventas}$
rota	Rotación de activos	$\text{Ventas} / \text{Activos totales}$
margenb	Margen bruto	$\text{Utilidad bruta} / \text{Ventas}$
margen_operacional	Margen operativo	$\text{Utilidad operacional} / \text{Ventas}$
margen	Margen neto	$\text{Utilidad neta} / \text{Ventas}$
ractiv	ROA	$\text{Utilidad neta} / \text{Activos totales}$
rpatri	ROE	$\text{Utilidad neta} / \text{Patrimonio}$
niven	Nivel de endeudamiento	$\text{Pasivos totales} / \text{Activos totales}$
apaltot	Apalancamiento total	$\text{Pasivos totales} / \text{Patrimonio}$
apalc	Apalancamiento corto plazo	$\text{Pasivos corrientes} / \text{Patrimonio}$
activos_pasivos	Relación activos/pasivos	$\text{Activos totales} / \text{Pasivos totales}$
pasivo_corto_pasivo- _total	Deuda CP / Total	$\text{Pasivos corrientes} / \text{Pasivos totales}$

Fuente: Elaboración propia.

4.4. Preprocesamiento de los datos

Con el fin de reducir la influencia de valores extremos remanentes en los indicadores financieros, se aplicó winsorización por percentiles. En las variables con colas más pesadas se utilizó un recorte al 1 % inferior y 99 % superior, mientras que en variables relativamente más estables se aplicó un recorte más conservador al 0,5 % inferior y

Tab. 4: Dimensiones financieras e indicadores utilizados en los modelos

Dimensión	Indicadores incluidos	Interpretación
Liquidez	Razón corriente, razón de tesorería, CTNO/Ventas	Capacidad para cubrir obligaciones de corto plazo
Rentabilidad	Margen bruto, margen operacional, margen neto, ROA, ROE	Capacidad de generar utilidades
Endeudamiento y apalancamiento	Nivel de endeudamiento, apalancamiento total, apalancamiento de corto plazo, pasivo corriente/pasivo total	Carga financiera y riesgo de incumplimiento

Fuente: Elaboración propia.

99,5 % superior. Las variables sujetas a cada criterio se presentan en el Anexo 1.

Posteriormente, se evaluó la colinealidad entre predictores mediante una matriz de correlación (Anexo 2) y el factor de inflación de la varianza, VIF (Anexo 3). Este análisis permitió identificar redundancias moderadas, especialmente en algunas variables de endeudamiento; sin embargo, no se observaron niveles de multicolinealidad severa que obligaran a excluir predictores exclusivamente por este criterio.

Sobre las variables retenidas se aplicó la transformación de Yeo-Johnson, con el fin de reducir asimetrías, estabilizar la varianza y mejorar la adecuación funcional de los datos para modelos sensibles a la forma de la distribución, como la regresión logística y los modelos aditivos generalizados. Con el propósito de evitar filtración de información, esta transformación se ajustó únicamente sobre el conjunto de entrenamiento y posteriormente se aplicó al conjunto de validación.

4.5. Estrategia de partición, validación y entrenamiento

La base final fue dividida mediante una partición estratificada, destinando aproximadamente el 80 % de las observaciones al conjunto de entrenamiento y el 20 % restante al conjunto de validación. Esta estrategia permitió preservar la proporción de empresas insolventes y no insolventes en ambos subconjuntos, aspecto fundamental dada la naturaleza desbalanceada del problema. Para ambos horizontes, la base final estuvo conformada por 27.926 empresas, de las cuales 22.340 se utilizaron para entrenamiento y 5.586 para validación.

Sobre el conjunto de entrenamiento se implementó validación cruzada estratificada de cinco particiones. Este procedimiento permitió evaluar diferentes configuraciones de los modelos manteniendo la estructura de clases en cada *fold*. Una vez seleccionada la mejor configuración, el modelo final fue reentrenado sobre la totalidad del conjunto de entrenamiento y posteriormente evaluado sobre el conjunto de validación, reservado exclusivamente para medir el desempeño fuera de muestra.

4.6. Especificación de los modelos

Se estimaron y compararon tres familias de modelos: regresión logística, modelos aditivos generalizados (GAM) y algoritmos de boosting implementados mediante XGBoost. Esta selección permitió contrastar un enfoque estadístico tradicional, un enfoque semiparamétrico capaz de capturar relaciones no lineales y una técnica avanzada de aprendizaje automático.

En la regresión logística, el desbalance de clases se abordó mediante ponderación manual de la clase minoritaria, utilizando esquemas del tipo $class-weight = \{0:1, 1:k\}$, donde la clase 0 corresponde a empresas no insolventes y la clase 1 a empresas insolventes. Asimismo, se evaluaron distintos umbrales de clasificación con el propósito de ajustar el equilibrio entre detección temprana de insolvencias y generación de falsas alertas.

En el caso del modelo GAM, el desbalance de clases se trató mediante pesos de observación calculados con el criterio $class-weight = balanced$. Dado que la baja frecuencia de la insolvencia podía producir pesos excesivamente altos y afectar la convergencia, dichos pesos fueron acotados mediante un valor máximo y posteriormente normalizados. Esta estrategia permitió asignar mayor importancia relativa a la clase minoritaria sin comprometer la estabilidad numérica del modelo.

Para XGBoost, el tratamiento del desbalance se realizó mediante el parámetro $scale-pos-weight$, el cual incrementa el peso relativo de la clase positiva dentro de la función de pérdida. Se evaluaron distintas configuraciones de este parámetro, incluyendo valores manuales y fracciones del cociente entre empresas no insolventes e insolventes. Adicionalmente, se ajustaron hiperparámetros relacionados con profundidad de árbol, tasa de aprendizaje, regularización y número de iteraciones, con el fin de controlar la complejidad del modelo y mejorar su capacidad de generalización.

4.7. Criterios de evaluación y selección del modelo

La comparación de los modelos se realizó mediante métricas apropiadas para problemas de clasificación desbalanceada y coherentes con el objetivo de alerta temprana de la investigación. En este contexto, el interés principal no radica únicamente en clasificar correctamente la mayoría de empresas no insolventes, sino en identificar de manera oportuna aquellas firmas que presentan un riesgo elevado de ingresar en procesos de insolvencia (D. Correa y Lopera, 2019; Perez et al., 2017).

Por esta razón, la evaluación priorizó la sensibilidad (*recall*) y el Error Tipo II. La sensibilidad mide la proporción de empresas insolventes correctamente identificadas por el modelo, mientras que el Error Tipo II representa aquellas empresas insolventes clasificadas erróneamente como no insolventes. Dado que el propósito del estudio es contribuir a la detección temprana del deterioro financiero, minimizar este último error resulta especialmente relevante, aun cuando ello pueda implicar un incremento moderado en las falsas alertas.

De forma complementaria, se consideraron el Error Tipo I, el coeficiente de correlación de Matthews (MCC) y el área bajo la curva Precisión-Recall (PR-AUC). El Error Tipo I permite cuantificar la proporción de empresas sanas clasificadas erróneamente como insolventes, aspecto importante para evaluar el costo de emitir alertas innecesarias. El MCC se utilizó como una medida sintética de desempeño, particularmente útil en escenarios de desbalance de clases, mientras que el PR-AUC permitió evaluar la capacidad discriminante del modelo sobre la clase minoritaria.

En consecuencia, la selección del modelo más adecuado no se basó en una única métrica, sino en una jerarquía de criterios consistente con el enfoque de alerta temprana. En primer lugar, se privilegió una mayor sensibilidad y un menor Error Tipo II; en segundo lugar, se consideró el PR-AUC como medida de capacidad discriminante sobre la clase insolvente; y, de forma complementaria, se evaluaron el MCC y el Error Tipo I para balancear capacidad predictiva y costo de falsas alarmas.

5. Resultados

5.1. Comparación financiera entre grupos

Para esta comparación se empleó la diferencia de medianas y la prueba no paramétrica de Wilcoxon–Mann–Whitney, con el fin de determinar si los indicadores financieros presentan diferencias estadísticamente significativas entre empresas insolventes y no insolventes. Bajo un nivel de significancia del 5 %, valores p inferiores a 0.05 conducen al rechazo de la hipótesis nula de igualdad de distribuciones, lo que sugiere que el indicador tiene capacidad para discriminar entre ambos grupos.

Para el horizonte 2024 (véase Tabla 5), se observa que las empresas insolventes presentan una mediana inferior en la relación activos-pasivos frente a las no insolventes, lo que indica una menor capacidad de respaldo de activos sobre pasivos. Asimismo, registran una menor razón corriente (*raz*) y una menor razón de tesorería (*teso*), lo que sugiere una menor capacidad de pago de corto plazo. En contraste, los indicadores de endeudamiento (*niven*) y apalancamiento total (*apaltot*) son superiores en el grupo insolvente. De forma consistente, en la dimensión de rentabilidad estas empresas presentan medianas más bajas en margen bruto, margen operacional, margen neto, ROA (*ractiv*) y ROE (*rpatri*), lo que refleja un deterioro operativo y financiero previo al evento de insolvencia. En conjunto, los resultados de la prueba evidencian diferencias estadísticamente significativas en la mayoría de los indicadores financieros, confirmando su utilidad para discriminar entre empresas insolventes y no insolventes. Para el horizonte 2024–2025 (véase Tabla 6), la comparación de medianas confirma un patrón financiero similar al observado en 2024, pero con mayor fuerza en algunas variables de apalancamiento y capital de trabajo. Las empresas clasificadas como riesgo presentan una mediana superior en apalancamiento total, nivel de endeudamiento lo que indica mayores niveles de endeudamiento y presión financiera sobre el patrimonio. También muestran menor activos-pasivos, menor razón corriente y razón de tesorería, evidenciando menor solvencia patrimonial y menor capacidad de pago de corto plazo. En rentabilidad, las empresas en riesgo tienen medianas inferiores en los respectivos márgenes y rentabilidades tanto del patrimonio como de activos. Esto sugiere menor generación de utilidad antes del evento de insolvencia.

Tab. 5: Diferencias entre grupos a un año (2024)

Variable	Mediana NoRiesgo	Mediana Riesgo	Diferencia	P-valor
activos_pasivos	2,222	1,271	−0,951	0,000
apaltot	0,686	1,607	0,921	0,000
raz	2,078	1,300	−0,778	0,000
niven	0,443	0,781	0,338	0,000
pasivo_corto_pasivo_total	0,711	0,463	−0,248	0,000
rota	0,631	0,459	−0,172	0,055
teso	0,185	0,025	−0,160	0,000
apalc	0,349	0,501	0,152	0,326
margenb	0,359	0,240	−0,118	0,000
margen_operacional	0,082	−0,011	−0,093	0,000
margen	0,042	−0,046	−0,088	0,000
ctno_ventas_preciso	0,170	0,250	0,080	0,192
rpatri	0,057	0,011	−0,047	0,000
ractiv	0,025	−0,022	−0,046	0,000

Nota. La diferencia es la mediana del grupo Riesgo menos la mediana del grupo NoRiesgo. *Nota.* P-valor corresponden a la prueba de Wilcoxon–Mann–Whitney

Fuente: Elaboración propia.

5.2. Resultados de los modelos predictivos

5.2.1. Horizonte 2024

En el horizonte de un año, el conjunto de entrenamiento quedó compuesto por 22.340 empresas, de las cuales 240 correspondieron a casos insolventes y 22.100 a no insolventes. Por su parte, el conjunto de validación estuvo conformado por 5.586 empresas, incluyendo 60 casos insolventes y 5.526 no insolventes.

La matriz de confusión presentada en la Tabla 7 muestra que los tres modelos lo gran identificar una proporción relevante de empresas que posteriormente entran en insolvencia, aunque con diferencias importantes en el número de falsas alertas generadas. La regresión logística identificó correctamente 42 de los 60 casos insolventes y generó 528 falsos positivos. El GAM detectó 41 casos y redujo los falsos positivos a 493. Por su parte, XGBoost alcanzó la mayor capacidad de detección, con 47 casos insolventes correctamente clasificados, aunque a costa de 752 falsos po-

Tab. 6: Diferencias entre grupos a dos años (2024–2025)

Variable	Mediana NoRiesgo	Mediana Riesgo	Diferencia	P-valor
apaltot	0,681	1,716	1,036	0,000
activos_pasivos	2,238	1,303	−0,935	0,000
raz	2,084	1,390	−0,694	0,000
niven	0,440	0,759	0,319	0,000
apalc	0,347	0,625	0,278	0,000
pasivo_corto_pasivo_total	0,714	0,504	−0,210	0,000
teso	0,188	0,028	−0,159	0,000
margenb	0,360	0,246	−0,115	0,000
ctno_ventas_preciso	0,169	0,281	0,112	0,002
margen_operacional	0,083	0,011	−0,072	0,000
margen	0,042	−0,011	−0,053	0,000
rpatri	0,058	0,016	−0,042	0,000
rota	0,630	0,591	−0,039	0,392
ractiv	0,025	−0,005	−0,030	0,000

Nota. La diferencia corresponde a la mediana del grupo Riesgo menos la mediana del grupo NoRiesgo. *Nota.* P-valor corresponden a la prueba de Wilcoxon–Mann–Whitney

Fuente: Elaboración propia.

sitivos. Estos resultados sugieren que, mientras los modelos tradicionales presentan un comportamiento más equilibrado, XGBoost adopta una estrategia más agresiva en la identificación de empresas en riesgo.

Desde la perspectiva de alerta temprana, las métricas de la Tabla 8 muestran que XGBoost presenta el mejor desempeño relativo. En particular, alcanza la mayor sensibilidad (78 %), el menor Error Tipo II (22 %) y la mayor PR-AUC (0.1263), lo que indica una mayor capacidad para identificar empresas que efectivamente entrarían en insolvencia. En contraste, la regresión logística registra una sensibilidad de 70 %, un Error Tipo II de 30 %, un MCC de 0.2058 y un Error Tipo I de 10 %, ubicándose en una posición intermedia. El GAM presenta una sensibilidad ligeramente inferior (68 %), pero logra el menor Error Tipo I (9 %) y el mayor MCC (0.2083), lo que lo convierte en la alternativa más equilibrada en términos de clasificación global y control de falsas alarmas.

En consecuencia, para el horizonte 2024, XGBoost resulta preferible bajo un enfoque de alerta temprana, dado que maximiza la detección de empresas insolventes y

minimiza el Error Tipo II. No obstante, esta ventaja se obtiene a costa de un mayor Error Tipo I, lo que implica un aumento en las alertas incorrectas.

Tab. 7: Matriz de confusión – Horizonte 2024

Modelo	Clase real	Predicción		Total
		Insolvente	No insolvente	
Logística	Insolvente	42	18	60
	No insolvente	528	4998	5526
	Total	570	5016	5586
GAM	Insolvente	41	19	60
	No insolvente	493	5033	5526
	Total	534	5052	5586
XGBoost	Insolvente	47	13	60
	No insolvente	752	4774	5526
	Total	799	4787	5586

Fuente: Elaboración propia.

Tab. 8: Métricas de desempeño de los modelos en 2024

Modelo 2024	Sensibilidad	MCC	Error Tipo I	Error Tipo II	PR-AUC
Regresión logística	70 %	0.2058	10 %	30 %	0.1079
GAM	68 %	0.2083	9 %	32 %	0.1055
XGBoost	78 %	0.1906	14 %	22 %	0.1263

Fuente: Elaboración propia.

5.2.2. Horizonte 2024–2025

En el horizonte de dos años, el conjunto de entrenamiento incluyó 451 empresas insolventes y 21.889 no insolventes, mientras que el conjunto de validación estuvo compuesto por 113 empresas insolventes y 5.473 no insolventes.

La matriz de confusión reportada en la Tabla 9 muestra nuevamente que los tres modelos identifican una fracción importante de las empresas que posteriormente ingresan en insolvencia, aunque con distintos costos operativos. La regresión logística

detectó 76 de los 113 casos insolventes y generó 681 falsos positivos. El GAM identificó 75 casos y redujo los falsos positivos a 643. Por su parte, XGBoost alcanzó la mayor capacidad de detección, con 90 casos correctamente clasificados, aunque con 849 falsos positivos. Al igual que en el horizonte de un año, los resultados evidencian que XGBoost privilegia la detección de la clase insolvente, incluso a costa de emitir un mayor número de falsas alertas.

Las métricas de la Tabla 10 confirman este patrón. XGBoost alcanza la mayor sensibilidad (80 %), el menor Error Tipo II (20 %) y la mayor PR-AUC (0.1251), lo que lo posiciona como el modelo más consistente con un enfoque de alerta temprana. En contraste, la regresión logística presenta una sensibilidad de 67 %, un Error Tipo II de 33 % y el mayor MCC (0.2550), reflejando un mejor balance global entre aciertos y errores. El GAM registra una sensibilidad de 66 %, un Error Tipo II de 34 %, un MCC de 0.2298 y un Error Tipo I similar al de la regresión logística (12 %), por lo que puede interpretarse como una alternativa intermedia.

En consecuencia, para el horizonte 2024–2025, XGBoost vuelve a sobresalir como la mejor alternativa bajo el criterio de detección temprana, al maximizar la proporción de empresas insolventes correctamente identificadas y minimizar las omisiones. Sin embargo, este resultado también implica aceptar un mayor Error Tipo I (16 %), es decir, un mayor volumen de falsas alertas frente a los modelos tradicionales.

Tab. 9: Matriz de confusión – Horizonte 2024–2025

Modelo	Clase real	Predicción		
		Insolvente	No insolvente	Total
Logística	Insolvente	76	37	113
	No insolvente	681	4792	5473
	Total	757	4829	5586
GAM	Insolvente	75	38	113
	No insolvente	643	4830	5473
	Total	718	4868	5586
XGBoost	Insolvente	90	23	113
	No insolvente	849	4624	5473
	Total	939	4647	5586

Fuente: Elaboración propia.

Tab. 10: Métricas de desempeño de los modelos en 2024–2025

Modelo 2024–2025	Sensibilidad	MCC	Error Tipo I	Error Tipo II	PR-AUC
Regresión logística	67 %	0.2550	12 %	33 %	0.1183
GAM	66 %	0.2298	12 %	34 %	0.1179
XGBoost	80 %	0.2414	16 %	20 %	0.1251

Fuente: Elaboración propia.

5.2.3. Síntesis comparativa

Teniendo en cuenta ambos horizontes de predicción, se puede inferir que los resultados muestran un patrón consistente. en donde el XGBoost presenta la mayor sensibilidad, el menor Error Tipo II y la mayor PR-AUC tanto en 2024 como en 2024–2025, lo que confirma su superioridad relativa bajo un enfoque de alerta temprana. En contraste, los modelos tradicionales, particularmente el GAM en 2024 y la regresión logística en 2024–2025, exhiben un mejor equilibrio global reflejado en mayores valores de MCC y menores errores de Tipo I. Por lo tanto los resultados anteriores sugieren que la elección del modelo depende del criterio de decisión: si el objetivo central es minimizar la omisión de empresas en riesgo, XGBoost resulta preferible; si se privilegia un balance más conservador entre detección y falsas alarmas, los modelos tradicionales siguen ofreciendo ventajas relevantes.

6. Discusión y conclusiones

La literatura revisada muestra que la predicción de insolvencia empresarial ha evolucionado desde modelos tradicionales hacia metodologías más flexibles, especialmente en contextos donde la insolvencia constituye un evento raro y existe un fuerte desbalance entre clases. los resultados de esta investigación evidencian que los enfoques no tradicionales presentan una mejor capacidad para identificar empresas en riesgo frente a los modelos lineales convencionales. Asimismo, se confirma que los indicadores de liquidez, rentabilidad y endeudamiento continúan siendo una base válida para la predicción de insolvencia, aunque su utilidad aumenta cuando se combinan con algoritmos capaces de captar relaciones no lineales, interacciones complejas y patrones difíciles de detectar mediante metodologías tradicionales. Bajo el enfoque de alerta temprana adoptado en esta investigación, XGBoost presentó el mejor desem-

peño en ambos horizontes de predicción, al registrar la mayor sensibilidad, el menor Error Tipo II y la mayor PR-AUC. Este resultado indica una mayor capacidad para identificar oportunamente empresas que efectivamente entrarían en insolvencia. No obstante, esta mejora estuvo acompañada de un mayor Error Tipo I, lo que refleja el intercambio entre detectar más casos reales y generar más falsas alertas. En consecuencia, se concluye que, para el caso colombiano, los modelos de aprendizaje automático ofrecen una ventaja clara frente a los modelos estadísticos tradicionales cuando el objetivo central es minimizar la omisión de empresas en riesgo. Sin embargo, si se prioriza un balance más conservador entre detección y falsas alarmas, la regresión logística y el GAM siguen siendo alternativas útiles.

7. Referencias

- Altman. (1968). financial ratios, discriminant analysis and prediction corporate bankruptcy. *Experts systems with applications*, 23(4), 589–609.
- Aristizabal, J. (2025). *Modelo de predicción de default en pymes de la ciudad de medellín*. Universidad EIA.
- Brédart, X., y Correa-Mejía, D. (2022). Bankruptcy prediction modeling in real-world conditions: A contrast of boosting algorithm and logistic regression. *Recherches en Sciences de Gestion*, 152(152), 127-153. doi: 10.3917/resg.152.0127
- Confecamaras. (2018). *Nuevos hallazgos de la supervivencia y crecimiento de las empresas en colombia*. (<https://confecamaras.org.co/wp-content/uploads/2024/01/cartilla17.pdf> [Accessed: 27/10/2025])
- Confecamaras. (2023). *reporte de creacion y supervivencia de empresas colombianas*. (<https://confecamaras.org.co/wp-content/uploads/2024/01/estudio-supervivencia-mayo-9.pdf> [Accessed: 26/05/2025])
- Correa, D., y Lopera, M. (2019). pronostico de insolvencia empresarial en colombia a traves de indicadores financieros. *Panorama economico*, 27(2), 510–526.
- Correa, D., y Lopera, M. (2020). Financial ratios as a powerful instrument to predict insolvency; a study using boosting algorithms in colombian firms. *Journal of Management and economics for iberoamerica*, 36(55), 229–238.
- Correa, N. (2023). Regresión logística técnica de machine learning para predicciones académicas. *Xicua Boletín científico*, 12, 71–80.
- Cruz, L. V. (2022). *Crisis empresarial en colombia, probabilidad de entrar en proceso de insolvencia 2016-2019*. . Universidad de los andes.
- Franco, Y. A. (2023). Machine learning aplicado a dificultades financieras y quiebra empresarial: una revision de literatura. *ciencias multidisciplinarias*, 3(4), 276–290.
- Iparraguirre-Villanueva, O., y Cabanillas-Carbonell, M. (2024). Predicting business bankruptcy: A comparative analysis with machine learning models. *Journal of Open Innovation: Technology, Market, and Complexity*, 10(3), 100375. Descargado de <https://www.sciencedirect.com/science/article/pii/S2199853124001690> doi: <https://doi.org/10.1016/j.joitmc.2024.100375>
- Kumar, P., y Ravi, P. (2007). Bankruptcy prediction in banks and firms via statistical and intelligent techniques – a review. *European Journal of Operational Research*, 180(1), 1-28. Descargado de <https://www.sciencedirect.com/science/article/pii/S0377221706008769> doi: <https://doi.org/10.1016/>

- j.ejor.2006.08.043
- Liu, y cols. (2022, 11). Predicting and interpreting financial distress using a weighted boosted tree-based tree. *Engineering Applications of Artificial Intelligence*, 116, 105466. doi: 10.1016/j.engappai.2022.105466
- Martinez, O. (2003). determinantes de fragilidad en las empresas colombianas.
- Mazo, M. (2022). Modelos aditivos generalizados.
- Molina, M., y Gonzales, K. (2024). *Prediccion de insolvencia economica en pymes colombianas mediante aprendizaje automatico*. . Universidad los libertadores.
- Perez, J., y cols. (2017). estimacion de la probabilidad de riesgo de quiebra en las empresas colombianas apartir de un modelo de eventos raros. *Cuad.Admon.Ser.Organ.*, 30(54), 7–38.
- Ramirez, S., y Roa, M. (2015). Modelos de prediccion de alerta temprana para riesgo de quiebra de pymes sector industrial de bogóta.
- Salgado, J. D. M. (2018). *Analisis discriminante multiple para la estimacion de probabilidad de insolvencia en empresas del sector industrial del distrito de bogota*. . Universidad nacional de colombia.
- Superintendencia de sociedades. (2025). *Insolvencia en colombia datos y cifras*. (<https://www.supersociedades.gov.co/web/procedimientos-de-insolvencia/informes> [Accessed: 27/10/2025])
- Tinoco, M., y Wilson, N. (2013). Financial distress and bankruptcy prediction among listed companies using accounting, market and macroeconomic variables. *International Review of Financial Analysis*, 30(C), 394-419.
- Valencia, C., y cols. (2019). Generalized additive model with embedded variable selection for bankruptcy prediction: Prediction versus interpretation. *Cogent Economics & Finance*, 7(1), 1597956.
- Zhang, y cols. (2024). Bankruptcy prediction of listed companies based on machine learning model. , 563–567. Descargado de <https://doi.org/10.1145/3724154.3724247> doi: 10.1145/3724154.3724247

8. Anexos

Anexo 1. Agrupación de variables y criterios de winsorización

Grupo de variables	Variables	Límites de winsorización
Grupo 1	Razón corriente, razón de tesorería, margen neto, margen operacional, activos/pasivos, apalancamiento de corto plazo, apalancamiento total y CTNO/Ventas	Percentiles 1 % y 99 %
Grupo 2	Rotación de activos, margen bruto, rentabilidad del activo (ROA), rentabilidad del patrimonio (ROE), nivel de endeudamiento y pasivo corriente/pasivo total	Percentiles 0,5 % y 99,5 %

Nota: La winsorización se aplica con el fin de mitigar el efecto de valores extremos y mejorar la robustez de los modelos.

Fuente: Elaboración propia.




Fig. 1: Anexo 2. Matriz de correlación entre variables explicativas

Anexo 3. Resultados del factor de inflación de la varianza (VIF)

Variable	VIF
apalc_win	4.2290
pasivo_corto_pasivo_total_win	4.1130
apaltot_win	4.0540
niven_win	3.2050
margenb_win	2.4520
margen_win	2.1550
margen_operacional_win	2.1380
raz_win	2.1010
rota_win	2.0790
teso_win	1.7910
ractiv_win	1.7380
activos_pasivos_win	1.6340
rpatri_win	1.3210
ctno_ventas_preciso_win	1.1910

Fuente: Elaboración propia.