

INSUFICIENCIA CARDIACA

ANDRES CERQUERA MEJIA, ESPECIALIZACIÓN EN ESTADÍSTICA
UNIVERSIDAD NACIONAL DE COLOMBIA-MEDELLÍN
2021

RESUMEN

Se analiza un conjunto de datos de 299 pacientes con insuficiencia cardíaca recopilados en el año 2015, en el se incluye el mes de seguimiento de cada paciente, su estilo de vida y datos clínicos.

Los 299 pacientes tenían disfunción sistólica ventricular izquierda y Tuvieron fallas cardíacas previas que los pusieron en clases III o IV de la clasificación de la New York Heart Association (NYHA) de las etapas de la insuficiencia cardíaca.

Se emplean varios modelos de clasificación de machine learning para predecir la supervivencia de los pacientes y clasificar las características correspondientes a la mayoría factores de riesgo importante.

También se realizó un análisis de supervivencia para determinar la probabilidad de supervivencia de los pacientes, el análisis de supervivencia identifica claramente a la creatinina sérica y la fracción de eyección como las dos características más relevantes, luego se construyeron los modelos de predicción de aprendizaje automático basados en estos dos factores y el tiempo.

INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) matan aproximadamente 17 millones de personas en todo el mundo cada año[1]. Son la principal causa de muerte a nivel mundial: cada año mueren más personas por ECV que por otra causa.

Se exhibe principalmente como infarto de miocardio e insuficiencia cardíaca.

La insuficiencia cardíaca ocurre cuando no puede bombear la suficiente sangre para satisfacer las necesidades del cuerpo.

Los registros médicos, las características corporales y las pruebas de laboratorio clínico se pueden analizar para hacer análisis estadísticos destinados a resaltar patrones y correlaciones que de otro modo serían indetectables por los médicos.

Los modelos de machine learning pueden predecir la supervivencia de los pacientes a partir de sus datos e identificar las características más importantes. Hecho que destaca en que se puede convertir en una herramienta para el apoyo médico.


METODOLOGÍA

Se emplearon métodos de aprendizaje automático para la clasificación binaria, donde se tuvo en cuenta el parámetro de exactitud, sensibilidad y especificidad y un análisis de supervivencia.

RESULTADOS



VARIABLES CATEGÓRICAS

Columna1	fallecidos	no_fallecidos	total
fumar	10%	22%	32%
no fumar	22%	46%	68%
anemia	15%	28%	43%
no anemia	17%	40%	57%
hipertension	13%	22%	35%
no_hipertension	19%	46%	65%
hombres	21%	44%	65%
mujeres	11%	24%	35%
diabetes	13%	28%	41%
no_diabetes	19%	39%	58%




Min	1st Qu	median	mean	3rd Qu	Max
40	51	60	60.8	70	95

	Min	1st QU	Median	means	3rd QU	Max
CREATINA QUINASA microg/litro	23.0	116.5	250.0	581.8	582.0	7861.0
PLAQUETAS (KiloPla/Microlitro)	251000	212500	262000	263358	3033500	850000
FRACCION EYECCION(%)	14	30	38	38.083	45	80
CREATININA (milig/decilitros)	0.5	0.9	1.1	1.39	1.4	9.4
NIVEL DE SODIO(milieg/ litro	113	134	137	136.63	140	148



ANÁLISIS DE SUPERVIVENCIA

El análisis de supervivencia examina y modela el tiempo que tardan en producirse lo que se denomina "eventos" aleatorios. Habitualmente dicho evento se asocia con la muerte del sujeto bajo estudio lo que justifica su nombre como análisis de supervivencia.[2]




Estimador Kaplan-meier

seguimiento	0	1	2	3	4	5	6	7	8	9
no_muerte	4	4	35	35	23	5	38	26	27	6
muerte	31	21	15	9	4	7	6	2	1	0

```
## Call: survfit(formula = Surv(tiempo, evento_muerte) ~ 1, data = heart,
## type = "kaplan-meier")
##
## time n.risk n.event survival std.err lower 95% CI upper 95% CI
## 4 299 1 0.997 0.00334 0.990 1.000
## 6 298 1 0.993 0.00471 0.984 1.000
## 7 297 2 0.987 0.00664 0.974 1.000
## 8 295 2 0.980 0.00811 0.964 0.996
## 10 293 6 0.960 0.01135 0.938 0.982
## 11 287 2 0.953 0.01222 0.930 0.977
## 13 284 1 0.950 0.01263 0.926 0.975
## 14 283 2 0.943 0.01340 0.917 0.970
## 15 281 2 0.936 0.01412 0.909 0.964
```

96 (32%) muertes y 203 (68%) no_muerte


GRÁFICACION DE CURVA DE SUPERVIVENCIA



TEST DE CÓMPARACION



$$H_0: h_1(t) = h_2(t) = \dots = h_k(t)$$
$$H_1: \text{ existen al menos dos } h_i(t) \text{ y } h_j(t) \text{ distintas}$$

Dadas dos o más curvas de supervivencia estas se pueden comparar a través de las funciones hazard asociadas a cada una de ellas. La resolución de este contraste se basa en un test ji-cuadrado. Si se rechaza la H_0 se concluye que existen al menos dos curvas de supervivencia distintas.



Puntos de corte

	cutpoint	statistic
edad	70.0	4.768062
fraccion_eyeccion	25.0	5.598649
creatinina	1.8	6.587226



MODELOS DE CLASIFICACIÓN

	Accuracy	sensitivity	specificity	kappa
arboles de decision	0.86	0.90	0.79	0.69
Adaboost	0.84	0.88	0.75	0.63
Super vector machine	0.81	0.87	0.71	0.58
K-nearest neighbors	0.90	0.97	0.75	0.75

Se concluye que el mejor modelo para clasificar el evento fallecimiento o no fallecimiento es vecinos más cercanos, ya que tiene el mayor valor de exactitud, esto con las variables tiempo, fracción de eyección y creatinina, por lo cual se corroboran otros estudios[3] en los que estas variables eran influyentes en cuanto a insuficiencia cardíaca.

REFERENCIAS

- [1] tomado de WORLD HEALTH ORGANIZATION https://www.who.int/health-topics/cardiovascular-diseases#tab=tab_1, fecha de consulta 2020.
- [2] Análisis de supervivencia en R studio, tomado de <https://rpubs.com/JavierMtzG/Supervivencia>
- [3] Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone, medical informatics and decision making, Davide chicco and Guisepe jurman, 2020.