

Anteproyecto de Ciencias-Estadística

NOMBRE

ANDRES HERNANDO CERQUERA MEJIA

Director:

Profesor Titular Juan Carlos Salazar Uribe , Ph,D



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Universidad Nacional de Colombia

Escuela de Estadística

Medellín, Colombia

2026

Índice

Índice	2
1. Información General	3
2. Resumen	3
3. Planteamiento Del problema	4
3.1. Título	5
3.2. Objetivos	5
3.2.1. Objetivo General	5
3.2.2. Objetivos Específicos	5
3.3. Marco Teórico	5
3.4. Datos Longitudinales	5
3.5. Modelo Lineal Mixto	6
3.6. Efectos Fijos y Aleatorios	6
3.7. Técnicas Machine Learning Con Efectos Mixtos	9
4. Antecedentes Del Problema Propuesto	9
5. Metodología	10
6. Cronograma	11
7. Compromisos	11
8. Referencias	12

1. Información General

Título: Ajuste y comparación de modelos mixtos clásicos y de Machine learning a datos de crecimiento craneofacial de la cohorte Damasco(CES-LPH).

Estudiante: Andres hernando Cerquera Mejia

Correo-e: ahcerqueram@unal.edu.co

Director:Juan Carlos Salazar Uribe

Profesor Titular - Universidad Nacional de Colombia

Escuela de Estadística

Correo-e: jccorrea@unal.edu.co

2. Resumen

El crecimiento es el mejor indicador global de la salud infantil, particularmente el crecimiento craneofacial en la primera infancia presenta diferentes variaciones en cuanto a tamaño, forma y función atribuidas a distintos factores(Luna Viera y Paternina Pestana, 2017). por otra parte la investigación concerniente al crecimiento craneofacial puede ser de dos tipos transversal y longitudinal. Sin embargo se mencionan limitaciones especialmente con los estudios longitudinales por el costo alto, el tamaño de la muestra requerida, pérdida de una parte de la muestra durante la investigación, por falta de disponibilidad de los individuos, por desplazamientos o por pérdida de interés por el estudio (Luna Viera y Paternina Pestana, 2017). En esta investigación se estudia el crecimiento craneofacial principalmente dos variables objetivos: altura facial anterior (AFH) y ángulo del plano mandibular (SN-MP) apartir de unas variables registradas en una población Mestiza en el Corregimiento de Damasco(Antioqua) y perteneciente al grupo CES-LPH, empleando técnicas de machine learning y modelos lineales mixtos, este estudio se ha venido realizando desde 1992 con una muestra de 54 niños y niñas de 6 a 8 años en el municipio de Damasco y aun continua en seguimiento por parte del Grupo de Investigación Labio y Paladar Hendido, Fisiología Oral y Crecimiento Craneofacial, CES-LPH, de la universidad CES con el apoyo del Grupo de Investigación de Estadística de la escuela de Estadística de la Universidad Nacional de Colombia - Sede Medellín.

3. Planteamiento Del Problema

El análisis del crecimiento craneofacial en la infancia y la juventud de las personas es de gran importancia. Ya que se sabe que el crecimiento general y craneofacial en estas etapas presenta grandes variaciones en tamaño, forma, función e intensidad, atribuidas a factores genéticos y ambientales. Cabe destacar que el énfasis que se le ha dado a la pubertad radica en que la velocidad de crecimiento en esta época es cerca del doble (Jiménez V. y Villegas T., 2013) y en consecuencia La relevancia de estos seguimientos radica en que en los últimos años diversos países como Suiza, Dinamarca, Argentina y España han construido sus propios patrones de crecimiento craneofacial como indicadores de salud individual y poblacional como soporte para instaurar políticas de salud publica y tratamientos craneofaciales a edades tempranas. Luna Viera y Paternina Pestana (2017)

En Colombia, se han desarrollado algunos estudios longitudinales Concernientes a este tema destacando los de Arboleda et al. (2011) y Hurtado et al. (1994). Sin embargo aun se requieren estudios en población mestiza que sirvan como referente para Colombia y que caractericen el crecimiento craneofacial su comportamiento, variabilidad y factores determinantes que influyen en su curso normal, para de esta manera construir patrones de referencia que apoyen los programas de promoción de salud, el diagnostico y tratamiento quirúrgico correctivo.

Por esta razón es necesario determinar Cuáles son los momentos de mayor crecimiento, variabilidad y magnitud en etapas tempranas de la pubertad por medio de modelos lineales Mixtos y modelos machine learning para datos longitudinales e identificar cuál de estos modelos explica con mejor precisión el crecimiento craneofacial con base en medidas craneofaciales como la altura facial anterior (AFH) y ángulo del plano mandibular (SN-MP) para de esta manera hacer predicciones a largo plazo del desarrollo y la evolución de este en la adolescencia.

3.1. Título

Ajuste y comparación de modelos mixtos clásicos y de Machine Learning a datos de crecimiento craneofacial de la cohorte Damasco(CES-LPH)

3.2. Objetivos

En esta sección se presentarán los objetivos general y específicos del problema planteado.

3.2.1. Objetivo General

Implementar y evaluar modelos machine learning y lineales mixtos para datos longitudinales de crecimiento craneofacial de la cohorte Damasco(CES-LPH)

3.2.2. Objetivos Específicos

- Generar medidas descriptivas de resumen para los datos longitudinales que describan el estado clínico actual del sujeto a partir de algunas variables obtenidas.
- Evaluar estadísticamente la importancia y dependencia entre las variables registradas.
- Comparar el desempeño de los modelos (modelo lineal mixto con intercepto aleatorio y machine learning tales como Random Forest,Regression Trees) y determinar cual se ajusta mejor de acuerdo a alguna métrica o criterio estadístico.

3.3. Marco Teórico

3.4. Datos Longitudinales

Los datos longitudinales se presentan cuando una característica en particular es observada varias veces en diferentes tiempos para cada sujeto, Además el análisis de

datos longitudinales es principalmente un análisis de datos correlacionados en donde por una parte los sujetos no se observan necesariamente en los mismos tiempos ni el mismo número de veces, y por otra, las covariables pueden ser diferentes para cada sujeto en los distintos tiempo, el estudio de los datos longitudinales presenta importantes ventajas y una de las más importantes es que permite distinguir variaciones en el tiempo de la característica que se mide en un individuo (variación intra-individual) junto con las variaciones debidas a las diferencias entre los individuos (variación inter-individual). Guzmán Aguilar (2012)

3.5. Modelo Lineal Mixto

Previamente a la definición del modelo matemático, se darán unos conceptos generales sobre componentes del modelo lineal mixto.

3.6. Efectos Fijos y Aleatorios

Efecto Aleatorio

Puede verse como aquel que se relaciona con situaciones donde una unidad es tomada al azar de una población caracterizada por varios niveles. Correa Morales (2016) Ejemplos: Humedad relativa, cuya medición tiene el efecto aleatorio de un punto a otro en l atmósfera.

Efecto fijo:

Estos efectos se asumen que son determinados a propósito y son efectos que son tratados como constantes conocidas o controladas. ejemplo: cuando se desea estimar el efecto de incorporar una mezcla, dada la temperatura. En este caso la temperatura es el efecto fijo.

Teniendo en cuenta los anteriores términos se presenta la forma del modelo general mixto en su forma sujeto específico Lange y Ryan (1989). si se Considera una muestra aleatoria de tamaño n y denote por $Y_i = (Y_{i1}, \dots, Y_{ini})$ al vector de respuestas del i -ésimo individuo, donde n_i es el respectivo numero de observaciones tomadas en dicho sujeto. El modelo lineal mixto individual esta dado por.

$$Y_i = X_i\beta + Z_ib_i + \epsilon_i$$

$$b_i \sim N(0, D)$$

$$\epsilon_i \sim N(0, R_i)$$

donde X_i y Z_i son las matrices de diseño para los efectos fijos y efectos aleatorios, respectivamente y que acompañan a los vectores β y b_i , $i = 1, \dots, n$ y b_i y ϵ_i son independientes. X_i es una matriz $n_i \times p$ de diseño, que representa los valores conocidos de las p covariables $x^1, \dots, x^p$, para cada uno de los n_i observaciones del i -ésimo sujeto, luego la matriz de diseño de los efectos fijos esta dada por :

$$\mathbf{X}_i = \begin{bmatrix} X_{1i}^{(1)} & X_{1i}^{(2)} & \dots & X_{1i}^{(p)} \\ X_{2i}^{(1)} & X_{2i}^{(2)} & \dots & X_{2i}^{(p)} \\ \vdots & \vdots & \ddots & \vdots \\ X_{ni}^{(1)} & X_{ni}^{(2)} & \dots & X_{ni}^{(p)} \end{bmatrix}$$

El vector $\beta = (\beta_1, \beta_2, \dots, \beta_p)$ es un vector de p coeficientes de regresión desconocidos (parámetros de efectos fijos) asociado con las p covariables utilizadas en la construcción de la matriz X_i . La matriz Z_i es una matriz ($n_i \times q$) de diseño, que representa los valores conocidos de las q covariables $Z^{(1)}, \dots, Z^{(q)}$, para el i -ésimo sujeto. Esta matriz es muy parecida a la matriz X_i en que representa los valores observados de covariables.

$$\mathbf{Z}_i = \begin{bmatrix} Z_{1i}^{(1)} & Z_{1i}^{(2)} & \dots & Z_{1i}^{(q)} \\ Z_{2i}^{(1)} & Z_{2i}^{(2)} & \dots & Z_{2i}^{(q)} \\ \vdots & \vdots & \ddots & \vdots \\ Z_{ni}^{(1)} & Z_{ni}^{(2)} & \dots & Z_{ni}^{(q)} \end{bmatrix}$$

Las columnas en la matriz Z_i representan los valores observados para las variables predictoras para el i -ésimo sujeto, que tiene efectos sobre la variable de respuesta continua que varia aleatoriamente entre sujetos. En muchos casos, los predictores con efectos que varían aleatoriamente entre sujetos están representados tanto en la matriz X_i y la matriz Z_i . El vector $b_i = (b_{i1}, \dots, b_{iq})$ para el i -ésimo sujeto representa un vector de orden q de efectos aleatorios asociado con las q covariables de la matriz Z_i . Suponemos que los efectos de orden aleatorio en el vector b_i siguen una distribución normal multivariada, con vector de medias 0 y una matriz de varianzas-covarianzas denotada por D . Los elementos a lo largo de la diagonal principal de la matriz D representan las variaciones de cada efecto aleatorio en b_i y los elementos fuera de la diagonal representan las covarianzas entre dos efectos aleatorios correspondientes. Debido a que hay q efectos aleatorios en el modelo asociado con el i -ésimo sujeto,

D es una matriz ($q \times q$) simétrica y definida positiva. Los elementos de esta matriz se muestran a continuación:

$$\mathbf{D} = \mathbf{Var}(\mathbf{b}_i) = \begin{bmatrix} Var(b_{1i}) & cov(b_{1i}, b_{2i}) & \dots & cov(b_{1i}, b_{qi}) \\ cov(b_{1i}, b_{2i}) & Var(b_{2i}) & \dots & cov(b_{2i}, b_{qi}) \\ \vdots & \vdots & \ddots & \vdots \\ cov(b_{1i}, b_{qi}) & cov(b_{2i}, b_{qi}) & \dots & Var(b_{qi}) \end{bmatrix}$$

Los elementos (varianzas y covarianzas) de la matriz D se definen como funciones de un conjunto pequeño de parámetros de covarianza almacenados en un vector denotado por θ_D . Finalmente, el vector ϵ_i es un vector de n_i errores con cada elemento en ϵ_i que denota el error asociado con una respuesta observada en t o en n_i ocasiones para el i -ésimo sujeto. Debido a que algunos sujetos pueden tener más observaciones que otras, el vector $\epsilon_i = (\epsilon_{i1}, \epsilon_{i2}, \dots, \epsilon_{ini})$ puede tener un número diferente de elementos. Supóngase que los errores n_i en el vector ϵ_i para un sujeto dado, i , son variables aleatorias que siguen una distribución normal multivariada, con un vector de medias 0 y una matriz de varianza-covarianza definida positiva R_i . Se asume que los errores asociados a diferentes sujetos son independientes entre sí, y que los vectores de errores $\epsilon_1, \dots, \epsilon_m$, y los efectos aleatorios $b_1, \dots, b_m$, son independientes el uno del otro. La forma general de la matriz R_i es:

$$\mathbf{R}_i = \mathbf{Var}(\epsilon_i) = \begin{bmatrix} Var(\epsilon_{1i}) & cov(\epsilon_{1i}, \epsilon_{2i}) & \dots & cov(\epsilon_{1i}, \epsilon_{qi}) \\ cov(\epsilon_{1i}, \epsilon_{2i}) & Var(\epsilon_{2i}) & \dots & cov(\epsilon_{2i}, \epsilon_{qi}) \\ \vdots & \vdots & \ddots & \vdots \\ cov(\epsilon_{1i}, \epsilon_{qi}) & cov(\epsilon_{2i}, \epsilon_{qi}) & \dots & Var(\epsilon_{qi}) \end{bmatrix}$$

Los elementos (varianzas y covarianzas) de la matriz R_i se definen como funciones de otro conjunto de parámetros de covarianzas en un vector denotado por θ_R . Al completar la notación para el modelo lineal mixto, el vector θ combina todos los parámetros de covarianza contenida en los vectores θ_D y θ_R . Estos parámetros se conocen con el nombre técnico de componentes de varianza y covarianza [Correa Morales et al., 2016].

Por último en el modelo lineal mixto, se estiman los parámetros de efectos fijos β , y los parámetros de covarianza θ (i.e., θ_D y θ_R , para la matriz D y R_i , respectivamente). Usualmente, esto se hace por medio de la estimación de máxima verosimilitud (MLE) y máxima verosimilitud restringida (REML).

3.7. Técnicas Machine Learning Con Efectos Mixtos

Como se indica en la introducción, uno de los objetivos del proyecto es evaluar el rendimiento de diferentes métodos de aprendizaje automático para predecir el comportamiento craneofacial de los pacientes del grupo de estudio. Esto también debe hacerse teniendo en cuenta la naturaleza altamente correlacionada del conjunto de datos y la estructura de medidas repetidas.

Para ello, por ahora se contempla el modelo clásico(modelo lineal mixto con intercepto aleatorio) y algunos algoritmos diferentes de aprendizaje automático(Random forest,Arboles de regresión y Gradiente Boosting) y se evaluará el desempeño de cada uno de ellos: En R hay algunos paquetes (entre paréntesis) que permiten realizar la implementación de las tecnicas machine learning:

- Random Forests for Longitudinal Data (**LongituRF**)
- Regression Trees with Random Effects for Longitudinal Data (**REEM-tree**)
- Boosted Multivariate Trees for Longitudinal Data (**boostmtree**)
- Machine Learning in R (**The caret Package**)

4. Antecedentes Del Problema Propuesto

Desde el año 1992 la Universidad CES esta desarrollando un estudio longitudinal que lleva aproximadamente 20 años de seguimientos bienales para evaluar el crecimiento craneofacial de una población mestiza del corregimiento de Damasco (Santa Bárbara, Antioquia), por medio de radiografías panorámicas y cefálicas laterales, El estudio comenzó con 48 niños con edades entre 5 y 8 años, quienes cursaban el primer grado escolar en la escuela de dicho corregimiento. Posteriormente, se completó la muestra hasta tener 54 sujetos, dichos niños presentaban apariencia facial normal y no habían recibido ningún tipo de tratamiento ortodóncico, hasta ahora es el estudio más largo y completo que se esta desarrollando en Colombia y América Latina y actualmente se encuentra bajo el liderazgo del investigador, Dr. Iván Darío Jiménez , director del grupo de investigación CES-LPH. Por otra parte Vale la pena destacar diferentes estudios longitudinales que se han desarrollado con respecto a esta temática entre los cuales se encuentran los de (Chvatal et al., 2005) y (Buschang

et al., 1988) en donde se elaboran curvas de crecimiento craneofacial de niños y niñas en etapa de crecimiento para inferir patrones de crecimiento de cada grupo y además se emplean modelos multinivel para predecir el crecimiento de este. También se hace ahinco en que el crecimiento craneofacial de la comunidad mencionada ya ha sido evaluado por medio de modelos lineales mixtos ajustados con splines como el de (Trilleras Mota, 2022) en donde el mejor modelo arrojó un buen resultado de predicciones a largo plazo comparado a los modelos lineales mixtos clásicos (con intercepto aleatorio), asimismo se resalta el estudio de (Jiménez et al., 2020) en donde se hace un estudio longitudinal (18 años de seguimiento) empleando modelos lineales mixtos en una población de mestizos en la ciudad de Medellín en donde se deduce que algunas medidas relacionadas con el crecimiento craneofacial se ven afectadas por la edad y sexo del individuo. Por otra parte vale la pena destacar un nuevo enfoque el cual integra la estructura de efectos aleatorios de los modelos de efectos mixtos en modelos de aprendizaje automático no lineales capaces de manejar datos longitudinales el cual es denominado el marco de aprendizaje automático de efectos mixtos (MEml) mixed-effect machine learning el cual ha sido implementado por (Ngufor, Van Houten, Caffo, Shah, y McCoy, 2019) y (Fuentes Claramonte, 2021) cuyos resultados demuestran el gran potencial que tienen estos modelos machine learning en su capacidad para predecir los cambios longitudinales en resultados clínicos reales con gran precisión, superando los modelos lineales mixtos clásicos.

5. Metodología

Se proponen las siguientes etapas para alcanzar los objetivos propuestos

- Explorar y analizar el comportamiento de las variables financieras y contables, aplicando criterios de exclusión basados en tasas de valores nulos y significancia estadística, Se priorizan variables con alta cobertura y poder discriminante.
- Aplicar técnicas de bootstrapping para estimar la estabilidad de las medianas y efectos de las variables en el modelo.
- Investigar y seleccionar modelos de machine learning supervisados que permitan la clasificación binaria, priorizando algoritmos robustos ante datos no imputados, como:

Regresión logística, Árboles de decisión (Random Forest, XGBoost) Support Vector Machines (SVM)

- Comparar los modelos para observar cuál de ellos tiene un mejor desempeño de acuerdo a métricas estadísticas(R²,Accuracy,RMSE entre otras)
- Realizar el análisis de resultados y concluir.

6. Cronograma

Actividad	Meses									
	1	2	3	4	5	6	7	8	9	10
Revisión de literatura	x	x	x	x	x	x	x			
Desarrollo del Marco teórico	x	x	x	x	x	x				
Análisis descriptivo y Desarrollo analítico			x	x	x	x				
Análisis de resultados			x	x	x	x	x	x		
Conclusiones						x	x	x	x	
Redacción del documento de tesis	x	x	x	x	x	x	x	x	x	x
Correcciones						x	x	x	x	x
Elaboración artículo					x	x	x	x	x	x

7. Compromisos

- Someter a revisión el artículo a al menos una revista nacional o internacional.
- Someter el proyecto a un evento académico

8. Referencias

- Arboleda, C., y cols. (2011). A mixed longitudinal anthropometric study of craniofacial growth of colombian mestizos 6-17 years of age. *European journal of orthodontics*, 33(4), 441-449.
- Buschang, P. H., y cols. (1988). Pubertal growth of the cephalometric point gnathion: multilevel models for boys and girls. *American journal of physical anthropology*, 77(3), 347-54.
- Chvatal, B. A., y cols. (2005). Development and testing of multilevel models for longitudinal craniofacial growth prediction. *American Journal of Orthodontics and Dentofacial Orthopedics*, 128 1, 45-56.
- Correa Morales, J., J y Salazar Uribe. (2016). *Introducción a los modelos mixtos*. Universidad Nacional de Colombia - Sede Medellín.
- Fuentes Claramonte, P. (2021). Machine learning methods for cross-sectional and longitudinal study of abnormal body fat distribution in hiv-infected individuals.
- Guzmán Aguilar, D. (2012). *Comparación de algunos r^2 como medidas de bondad de ajuste en modelos lineales mixtos*. . Universidad Nacional de Colombia.
- Hurtado, M., y cols. (1994). Estudio comparativo de crecimiento v desarrollo craneofacial en tres poblaciones diferentes (belmira, damasco v valle de aburra)..
- Jiménez, I. D., y cols. (2020). Facial growth changes in a colombian mestizo population: An 18-year follow-up longitudinal study using linear mixed models. *American journal of orthodontics and dentofacial orthopedics : official publication of the American Association of Orthodontists, its constituent societies, and the American Board of Orthodontics*, 157 3, 365-376.
- Jiménez V., I. D., y Villegas T., S. L. G., Luisa Fernanda. (2013, 06). Picos de crecimiento facial vertical antes de los 12 años de edad y su relacion con el desarrollo puberal en 44 mestizos colombianos sin tratamiento. *Revista Facultad de Odontología Universidad de Antioquia*, 24, 289 - 306. Descargado de http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0121-246X2013000100009&nrm=iso
- Lange, N., y Ryan, L. (1989). Assessing normality in random effects models. *The Annals of Statistics*, 624-642.
- Luna Viera, J. C., y Paternina Pestana, B. E. (2017). *Patrones de crecimiento general y craneofacial en niños de 0 a 5 años de cartagena*. Universidad de Cartagena.
- Ngufor, C., Van Houten, H., Caffo, B. S., Shah, N. D., y McCoy, R. G. (2019). Mixed effect machine learning: a framework for predicting longitudinal change

- in hemoglobin a1c. *Journal of biomedical informatics*, 89, 56–67.
- Trilleras Mota, M. (2022). *Implementación de modelos lineales mixtos flexibles a datos de crecimiento craneofacial en la cohorte ceslph damasco.* . Universidad Nacional de Colombia.